

# Derin Öğrenme Modelleri ile Eskiz Sınıflandırma Sketch Classification with Deep Learning Models

Fevziye İrem Eyiokur\*, Doğucan Yaman\*, Hazım Kemal Ekenel  
Bilgisayar Mühendisliği Bölümü  
İstanbul Teknik Üniversitesi  
İstanbul, Türkiye  
{eyiokur16, yamand16, ekenel}@itu.edu.tr

**Özetçe** —Eskiz çizimlerinde renk, doku gibi bilgilerin eksikliği, objelere ait detayların az olması ve kişinin çizim yeteneğine bağlı olarak eskiz imgelerinin anlaşılabilirliğinin farklı olması eskiz sınıflandırma problemini zor kılmaktadır. Bu çalışmada derin evrişimsel sinir ağı modellerinden yararlanılarak eskiz imgeleri sınıflandırma problemi ele alınmıştır. Evrişimsel sinir ağları ile ince-ayar yapılırken, alan uyarlamasının zayıf özneliliklere sahip eskiz imgelerinin sınıflandırma başarımı üzerindeki etkisi analiz edilmiş ve başarımı yaklaşık %3 artırdığı gözlemlenmiştir. TU Berlin eskiz veri kümesi üzerinde VGG-16 modeli ve iki aşamalı ince-ayar yaklaşımı kullanılarak %79,72 doğru sınıflandırma ile literatürdeki en yüksek başarımla elde edilmiştir.

**Anahtar Kelimeler**—*derin öğrenme, evrişimsel sinir ağı, eskiz sınıflandırma*

**Abstract**—Sketch classification problem is challenging due to several reasons, such as absence of color and texture information, lack of detailed information of objects, and the quality, which depends on drawing ability of the person. In this study, sketch classification problem is addressed by using deep convolutional neural network models. Specifically, the effect of domain adaptation is examined, when fine-tuning the convolutional neural networks for sketch classification. By employing domain adaptation, the classification accuracy is increased by around 3%. The proposed system, which utilizes VGG-16 network model and performs two-stage fine-tuning, outperforms the previous state-of-the-art approaches on the TU Berlin sketch dataset by reaching 79,72% accuracy.

**Keywords**—*deep learning, convolutional neural network, sketch classification*

## I. GİRİŞ


Eskiz çizimleri tarih boyunca iletişim, sanat, mühendislik gibi pek çok amaçla kullanılmışlardır [1], [8]. İlk çağlarda insanların mağara duvarlarına yaşadıkları olayları anlatan çizimler yapması, çocukların kendilerini ifade etmekte çizim yöntemini kullanması, ressamın iç dünyalarını resimleriyle dışa yansıtması eskiz kullanımına verilebilecek örneklerdir. Günümüzde özellikle telefon, tablet gibi dokunmatik cihazların yaygınlaşması ve insan-bilgisayar etkileşiminde meydana gelen gelişmeler eskiz çizimlerini popüler hale getirmiştir. Bu gelişmelerle birlikte bilgisayarla görü ve bilgisayar grafiği alanında araştırmacıların ilgisini çekmeye başlayan eskiz çizimleri, tanıma ve sınıflandırma üzerine yapılan araştırmalarda

aktif olarak yer edinmeye başlamıştır [6], [7], [10], [11]. Eskiz çizimlerini tanıma alanında yapılan çalışmaların amacı insan tarafından çizilmiş objelerin sınıflandırılmasıdır [8]. Eskiz çizimleri sınıflandırma, eskiz imgelerinin gerçek dünya imgelerinden farklı olarak yapı/doku, renk ve objeyle ilgili ayrıntı içermemesinden ve çizilen objenin gerçek haline benzerliği kişilerin çizim yeteneğiyle ilişkili olmasından dolayı zorlayıcı bir bilgisayarla görü problemi.

Eskiz imgeleri kullanan çalışmalarda, eskiz çizimlerini normal bir imge gibi kabul ederek yerel ve global öznelilikler çıkarılır ve bu özneliliklerden objeyi tanımak için faydalanılır. Eskiz tanıma alanında yapılan çalışmalara katkıda bulunmak amacıyla, 2012 ve 2016 yıllarında büyük çaplı veri kümeleri olan, TU Berlin eskiz veri kümesi [1] ve Sketchy veri kümesi [11] sunulmuştur. Eitz ve arkadaşlarının çalışmasında [1] sunulan TU Berlin veri kümesi eskiz çizimleri sınıflandırma alanında pek çok çalışmada kıyaslama standardı olmuştur. Yine aynı çalışmada insan gözlem başarısı ölçülmüş ve insanların bu veri kümesindeki eskiz obje çizimlerini %73,1 başarımla tanıdıkları bulunmuştur. İnsan ve bilgisayar performansını karşılaştırmak amacıyla görsel kelime çantası (bag-of-features) ve destek vektör makineleri (DVM) kullanarak yaptıkları sınıflandırmada %56 başarımla elde etmişlerdir. Bu çalışma sonucunda insanların bilgisayarlardan daha başarılı bir şekilde eskiz çizimlerini tanıyabildikleri ortaya konulmuştur. Fakat daha sonraki çalışmalarda sistemlerin insan performansını geçtiği gözlemlenmiştir.

Derin öğrenmeyi eskiz imgeleri üzerinde kullanmayı amaçlayan Yang ve arkadaşlarının çalışmasında [3] gerçek obje imgelerinden oluşan ImageNet [13] veri kümesi üzerinde eğitilmiş bir model, eskiz çizimleri üzerinde test edilmiş fakat yüksek bir başarımla elde edilememiştir. Çünkü model çoğu imge için, eğitildiği veri kümesinde yer alan karikatür sınıfı tahmininde bulunmaktadır. Eskiz çizimlerinin sınıflandırılması üzerine yapılan bir diğer çalışmada [2], 3 farklı alt ağ kullanılarak bütünsel bir ağ önerilmiştir. Bu alt ağlar sırasıyla gerçek dünya imgelerinden öznelilik çıkarma, eskiz çizimlerinden öznelilik çıkarma ve gerçek dünya imgeleri ile eskiz çizimleri arasındaki ortak yapıları keşfetme amacıyla kullanılmıştır ve farklı deney kümeleri alınarak elde edilen modellerin sonuçları incelenmiştir. Evrişimsel sinir ağları (ESA) ile tasarlanmış (hand-crafted) özneliliklerin birleştirilerek eskiz çizimi sınıflandırması yapılan Seddati ve arkadaşlarının çalışmasında [6] %75,42 sınıflandırma başarımına ulaşılmıştır. Sangkloy ve arkadaşları [11] ise eskiz çizimleri araştırma alanında yeni çalışmalar yapılabilmesi adına eskiz-gerçek imge çiftleri içe-

\*Yazarlar eşit katkıda bulunmuştur.



Şekil 1: İki aşamalı ince-ayar yaklaşımı.

ren geniş bir veri kümesi sunmuşlardır ve bu veri kümesi üzerinde eskiz arama (retrieval) çalışmalarında bulunmuşlardır. Eskiz çizimlerini sınıflandırma için *sketch-a-net* isimli bir ESA mimarisi önerilen Yu ve arkadaşlarının çalışmasında [5] ise alan adaptasyonu uygulanarak %74,9 sınıflandırma başarımı elde edilmiştir. İmgelerden elde edilen piksel tabanlı ve ardışık bilginin bir arada kullanıldığı bir diğer çalışmada [4] ESA ve tekrarlayan sinir ağı (RNN) mimarilerinden yararlanılarak %79,6 ile en yüksek başarımla elde edilmiştir.

Bu çalışmada sınıflandırma alanında sıkça başvurulmuş AlexNet [14], VGG-16 [15] ve GoogLeNet [16] derin öğrenme mimarileri kullanılmıştır. ImageNet veritabanı [13] üzerinde eğitilmiş olan bu modellere önce hedef veri kümesi ile aynı alanda yer alan bir başka veri kümesi üzerinde ince-ayar gerçekleştirilmiş, bu şekilde alana uyarlanan bu modellere hedef veri kümesi üzerinde tekrar ince-ayar yapılmıştır. Önerilen iki aşamalı ince-ayar yaklaşımı Şekil 1’de gösterilmiştir. Bu yaklaşım ile literatürdeki en yüksek eskiz sınıflandırma başarımına ulaşılmıştır.

Bildirinin kalan bölümleri şu şekilde düzenlenmiştir. Bölüm 2’de kullanılan ESA modelleri ve alan uyarlaması hakkında detaylı bilgi verilmiştir. Bölüm 3’te kullanılan veri kümeleri açıklanmış, elde edilen sonuçlar sunulmuş ve analiz edilmiştir. Bölüm 4’te ise çalışmanın katkıları ve nasıl geliştirilebileceği değerlendirilmiştir.

## II. YÖNTEM

Bu bölümde, kullanılan derin evrişimsel sinir ağları, alan uyarlaması ve transfer öğrenme hakkında bilgi verilmiştir.

### A. Evrişimsel Sinir Ağları

Bu çalışmada, eskiz çizimlerini tanımak ve sınıflandırmak amacıyla derin evrişimsel sinir ağlarından yararlanılmıştır. ESA mimarileri genellikle evrişim, öznitelik çıkarımı ve sınıflandırma gibi işlemlerden sorumlu art arda eklenmiş evrişimsel katmanlar ve bu katmanları takip eden tam bağlı sinir ağlarından oluşmaktadır. ESA mimarilerinin evrişimsel bölümü evrişim, örnekleme (pooling) ve küme normalizasyonu (batch normalization) gibi işlemleri gerçekleştirirken daha sonraki katmanlarda evrişimsel katmanlar tarafından imgeden öğrenilen ayırt edici özellikler sınıflandırma için kullanılır. Bu çalışmada ESA mimarilerinin son katmanında softmax kayıp fonksiyonundan yararlanılmıştır.


Bu çalışmada kullanılan ilk ESA mimarisi 2012 ILSVRC yarışmasını [12] kazanan ve AlexNet [14] olarak bilinen sinir ağı mimarisidir. AlexNet mimarisi [14] beş evrişimsel katman ve üç tam bağlı katmandan oluşan ve göreceli olarak az derin kabul edilebilecek bir mimaridir. AlexNet mimarisinden [14]

daha derin olan bir diğer mimari VGG mimarisidir ve VGG-16 ve VGG-19 olarak adlandırılan iki farklı versiyonu mevcuttur [15]. VGG-16 ve VGG-19 olarak adlandırılan versiyonları arasındaki fark evrişimsel katmanlarının sayısıdır [15]. VGG-19 mimarisinde fazladan üç evrişimsel katman yer almaktadır. Bu çalışmada VGG-16 [15] mimarisi kullanılmıştır. Bu mimari 16 evrişimsel katman ve 3 tam bağlı katmandan oluşmaktadır. Bu mimari ile çok sayıda küçük boyutta filtreler kullanılarak modelin içerdiği parametre sayısının azaltılabileceği önerilmiş ve ESA modellerinin karmaşıklığını azaltmaya yönelik önemli bir katkıda bulunulmuştur. Çalışmamızda kullanılan son ESA modeli ise GoogLeNet [16] olarak bilinen, 22 evrişimsel katman içeren, bununla birlikte AlexNet [14] mimarisinden 12 kat daha az parametreye sahip bir mimaridir. Bu mimaride sunulan ve inception olarak adlandırılan yeni yaklaşımda, girdi imgesi farklı filtrelerle ayrı ayrı filtrelenir, elde edilen sonuçlar birleştirilerek bir sonraki katmana aktarılır. Bu yaklaşımda aynı imgeden farklı filtrelemeler ile öznitelikler çıkarılarak başarıma ve öznitelik kalitesine katkıda bulunulmuştur. Aynı zamanda bu mimaride üç farklı derinlik seviyesinden sınıflandırma sonucu elde edilmektedir.

### B. Transfer Öğrenme ve Alan Uyarlaması

Transfer öğrenmede en önemli nokta ön eğitim için kullanılan veri kümesi ile hedef veri kümesi arasındaki alan benzerliğidir. Derin öğrenme kapsamında transfer öğrenme genel olarak iki farklı yolla uygulanabilir. Bunlardan biri ön eğitimli ESA modeli kullanarak hedef veri kümesinden doğrudan öznitelik çıkarmak ve bu öznitelikleri DVM gibi yöntemlerle sınıflandırmaktır. Bu yöntem genellikle hedef veri kümesinin çok küçük olması ve ESA eğitimi için yeterli veri içermemesi durumunda uygulanmaktadır. Bir diğer yöntem ise ön eğitimli model kullanarak hedef veri kümesi üzerinde ince-ayar gerçekleştirilmesidir. Bu yaklaşım orta ölçekli büyüklükteki hedef veri kümelerinde tercih edilmektedir [19]. ESA mimarilerinin ilk katmanları kenar, renk gibi temel özniteliklerle ilgilenirken, katmanlar ilerledikçe ve mimari derinleştikçe hedef veri kümesine özgü öznitelikler öğrenilmeye başlanır. Bu nedenle ince-ayar yapılırken ön eğitimli modelin ağırlıkları başlangıç ağırlıkları olarak atanır ve genellikle son katmanlarda yüksek öğrenim oranı kullanılarak bu katmanın veya katmanların hedef verisini daha fazla öğrenmesi sağlanır.

Bu çalışmada ImageNet veri kümesi [13] üzerinde ön eğitimli AlexNet [14], VGG-16 [15] ve GoogLeNet [16] modelleri kullanılarak eskiz çizimleri üzerinde ince-ayar gerçekleştirilmiştir. Toplamda 20000 eskiz imgeleri içeren TU Berlin eskiz veri kümesi [1] sıfırdan eğitim için yeterli miktarda veri içermediğinden transfer öğreniminden yararlanılmıştır. Literatürdeki daha önceki çalışmalarda [17], [18], problem için limitli veri olması durumunda ön eğitimli derin ESA modellerinin transferinin, sıfırdan eğitime göre daha yüksek bir başarımla sağladığı gösterilmiştir. Ek olarak, ESA modelleri yakın bir alandan transfer etmenin başarımla açısından daha verimli bir yaklaşım olduğu bulunmuştur. Bu bilgilerden yararlanılarak, bu çalışmada Şekil 1’de gösterildiği gibi iki aşamalı ince-ayar uygulanmıştır. İlk aşamada ImageNet veri kümesi [13] üzerinde ön eğitimli ESA modeli eskiz çizimleri içeren Sketchy veri kümesi [11] üzerinde ince-ayarılmıştır. Bu yolla alan uyarlaması sağlanmıştır. İkinci aşamada ise, Sketchy veri kümesi [11] üzerinde ince-ayarılmış model, ön



Şekil 2: TU Berlin eskiz veri kümesine ait örnek imgeler

TABLO I: Sketchy veri kümesi sınıflandırma sonuçları

Model	Test sonucu
AlexNet	%87,22
VGG-16	%88,28
GoogLeNet	%89,14

TABLO II: TU Berlin veri kümesi sınıflandırma sonuçları

Model	Test sonucu	Alan uyarlaması
AlexNet	%74,17	-
AlexNet	%75,66	+
VGG-16	%77,34	-
VGG-16	%79,72	+
GoogLeNet	%75,62	-
GoogLeNet	%78,69	+

eğitilmiş model olarak kullanılarak, hedefteki TU Berlin eskiz veri kümesi [1] üzerinde ince-ayar yapılmıştır.

### III. DENEYSEL SONUÇLAR

Bu bölümde kullanılan veri kümeleri hakkında bilgi verilmiş, yapılan deneyler açıklanmış ve sonuçları yorumlanmıştır. Sketchy veri kümesi [11] ve TU Berlin eskiz veri kümesi [1] üzerinde eskiz çizimlerinden nesne sınıflandırma ile ilgili deneyler gerçekleştirilmiş, veri kümelerinin %20'si her sınıftan eşit oranda imge olacak şekilde, test amacıyla ayrılmıştır. Geriye kalan %80'lik kısım eğitim için kullanılmıştır. Eğitim esnasında doğrulama amacıyla kullanılan veri, eğitim verisinden seçilerek ayrılmıştır.

ESA ile gerçekleştirilen eğitimlerde imgeler modellere uygun olarak yeniden boyutlandırılmıştır.  $256 \times 256$  piksel boyutuna getirilen imgeler modellere girdi olarak verilmiştir. ESA modelleri eğitim sırasında bu imgelerden rastgele 5 farklı imge alır ve bunları kullanarak eğitimi sürdürürler. AlexNet [14]  $227 \times 227$  boyutunda imgeler, VGG-16 [15] ve GoogLeNet [16] mimarileri ise  $224 \times 224$  boyutunda imgeler alır. Test aşamasında ise üç model de yine ilgili boyutlarda merkezden kesilmiş bir imge alır ve test işlemi bu imge üzerinde gerçekleştirilir. İnce-ayar gerçekleştirilirken ESA mimarilerinin son katmanı sınıf sayısı kadar çıktı verecek şekilde yeniden düzenlenir.

TABLO III: Sonuçların karşılaştırılması

Yaklaşım	Sonuç
ESA + Tasarlanmış öznitelikler [6]	%75,42
ESA [7]	%77,69
Sketch-a-Net [5]	%74,9
ResNet-18 + R-LSTM-R + R-FC [4]	%79,6
Görsel kelime çantası + DVM [1]	%56
Fisher vektör tabanlı [10]	%68,9
İnsan performansı [1]	%73
<b>VGG-16 alan uyarlaması</b>	<b>%79,72</b>

#### A. Veri Kümeleri

Bu çalışmada eskiz çizimleri içeren iki farklı veri kümesinden yararlanılmıştır. Hedef veri kümesi olan TU Berlin eskiz veri kümesi [1], 250 kategori ve 20000 eskiz imgesi içermektedir. Veri kümesi eşit dağılımlıdır ve sınıf başına 80 eskiz imgesi bulunmaktadır. İmgelerin tamamı farklı bir nesne içeren siyah beyaz çizimlerden oluşmaktadır, dolayısıyla eskiz imgeleri renk, doku gibi ek bilgiler barındırmamaktadır. Şekil 2'de TU Berlin eskiz veri kümesinden örnek imgeler gösterilmiştir.


Alan uyarlaması amacıyla kullanılan Sketchy veri kümesi [11] ise 125 sınıf ve toplamda 12500 farklı nesneye ait farklı açılarda çizilmiş 75421 imge içermektedir.

#### B. Değerlendirme

Sketchy veri kümesi [11] üzerinde yapılan deneylerin sonuçları Tablo I'de gösterilmiştir. Tabloda ilk sütun kullanılan ESA mimarisini, ikinci sütun ise test imgeleri üzerinde elde edilen sınıflandırma başarımını göstermektedir. En iyi sonuç GoogLeNet [16] modeli ile %89,14 doğru sınıflandırma oranıyla elde edilmiştir. Bu sonucu sırasıyla %88,28 ile VGG-16 [15] ve %87,22 ile AlexNet [14] takip etmektedir.

Hedef veri kümesi olan TU Berlin eskiz veri kümesi [1] üzerinde elde edilen sonuçlar Tablo II'de sunulmuştur. Tabloda birinci sütun kullanılan modeli, ikinci sütun test verisi üzerinde elde edilen tanıma/sınıflandırma başarımını ve son sütun ise alan uyarlamasının kullanılıp kullanılmadığını göstermektedir. Alan uyarlaması kullanılarak elde edilen sonuçlar iki aşamalı ince-ayar temsil etmektedir. Elde edilen diğer sonuçlar ise ImageNet [13] veri kümesi üzerinde eğitilmiş modelin ön eğitilmiş model olarak kullanılarak hedef veri kümesi olan TU Berlin veri kümesi [1] üzerinde doğrudan ince-ayar yapılmasıyla gerçekleştirilmiştir. Sonuçlar incelendiğinde en yüksek başarımın %79,72 sınıflandırma yüzdesi ile alan uyarlamasından yararlanılarak VGG-16 [15] mimarisiyle elde edildiği görülmüştür. Genel olarak alan uyarlamasının ortalama %2-3 seviyesinde bir başarımlı artışı sağladığı gözlemlenmiştir. Bu sonuçlar transfer öğrenme gerçekleştirilirken, hedef veri kümesine yakın bir alandan transferin yapılmasının, eskiz veri kümeleri gibi renk ve ayrıntılı (high level) öznitelikler içermeyen daha basit yapıları imgelerde dahi başarımlı üzerinde önemli bir artış sağladığını kanıtlamaktadır.

Tablo III'te, bu çalışmada elde edilen en yüksek başarımlı geçmiş çalışmalarla kıyaslanmaktadır. Alan uyarlaması uygulanarak iki aşamalı ince-ayar sonucunda elde edilen eskiz çizimleri sınıflandırma başarımı geçmiş çalışmaları geçerek %79,72 ile en yüksek değere ulaşmıştır. Bu çalışmamız ve



Şekil 3: CMC eğrileri. Sırasıyla AlexNet, VGG-16 ve GoogLeNet modellerine ait doğruluk-derece (rank) N grafikleridir.

son zamanlarda yapılan diğer çalışmalar göstermiştir ki bilgisayarların eskiz çizimleri tanıma ve sınıflandırma başarımı insanlardan daha iyi bir seviyededir.

TU Berlin eskiz veri kümesi [1] üzerinde yapılan test sonuçları incelendiğinde 17 sınıfta %100 sınıflandırma başarımı elde edilirken, %29'luk sınıflandırma başarımıyla en düşük başarımla en çok karışan sınıf *kamyonet* olmuştur. Birbiri ile en çok karışan sınıflar incelendiğinde sınıfların birbirlerine olan benzerlikleri dikkat çekmiştir. Bu sınıf çiftleri sırasıyla şunlardır: *tekerlek-lastik*, *araba(sedan)-yarış arabası*, *yüz-kafa*, *çay fincanı-fincan*. Şekil 3 sırasıyla AlexNet [14], VGG-16 [15] ve GoogLeNet [16] test sonuçlarına ait kümülatif eşleşme eğrilerini (CMC) göstermektedir. Modellerin ilk 2 tahmini incelendiğinde yaklaşık %85-87 sınıflandırma başarımı elde edildiği gözlemlenmiştir. Bu durum eskiz sınıflandırma alanındaki objelerin detay eksikliğinden ötürü birbirlerine benzer gözükmeye problemini doğrular niteliktedir. Örneğin, bir yarış arabasıyla bir sedan araba arasındaki farklar çizimde detaylandırılmadığı sürece model tarafından bu iki sınıfa ait objeler hatalı sınıflandırılabilmektedir. Ayrıca üç modelde de ilk 10 tahminde başarımın %95'in üzerine çıktığı, ilk 29 tahminde ise %99'u geçtiği görülmektedir.

#### IV. SONUÇ

Bu çalışmada derin evrimsel sinir ağları kullanılarak eskiz sınıflandırma problemi analiz edilmiştir. ESA modelleri ile sınıflandırma sonuçları sunulmuş, iki aşamalı inceleme yapılarak alan uyarlamasının eskiz sınıflandırma başarımı üzerindeki etkisi incelenmiştir. TU Berlin eskiz veri kümesi [1] üzerinde yapılan deneyler sonucunda önceki çalışmalarda elde edilen sonuçların üzerine çıkılmış, alan uyarlaması ve VGG-16 modeli ile %79,72 sınıflandırma başarımı elde edilmiştir. Renk, doku, objelere ait ayrıntı vb. bilgilerin eksikliği eskiz tanıma problemini zorlaştırmaktadır ve başarımların çok yüksek olmasına engel olmaktadır. Gelecek çalışmalarda veri artırımı ve eskiz imgelerine ait öznitelikleri artırma çalışmaları üzerinde durulacak ve elde edilen başarımlar iyileştirilmeğe çalışılacaktır. Ayrıca GAN [20] yaklaşımından da yararlanılması planlanmaktadır.

#### KAYNAKLAR

[1] M. Eitz, J. Hays, M. Alexa, "How do humans sketch objects?", *ACM Transactions on Graphics (TOG)*, vol. 31(4), ss. 44:1-10, 2012.  
[2] H. Zhang, S. Liu, C. Zhang, W. Ren, R. Wang, X. Cao, "SketchNet: Sketch classification with web images", *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, ss. 1105-1113, 2016.

[3] Y. Yang, T.M. Hospedales, "Deep neural networks for sketch recognition", *arXiv preprint arXiv:1501.07873*, 2015.  
[4] J.Y. He, X. Wu, Y.G. Jiang, B. Zhao, Q. Peng, "Sketch recognition with deep visual-sequential fusion model", *ACM on Multimedia Conference*, ss. 448-456, 2017.  
[5] Q. Yu, Y. Yang, F. Liue, Y.Z. Song, T. Xiang, T.M. Hospedales, "Sketch-a-Net: A deep neural network that beats humans", *International Journal of Computer Vision*, vol. 122, ss. 411-425, 2017.  
[6] O. Seddati, S. Dupont, S. Mahmoudi, "DeepSketch: Deep convolutional neural networks for sketch recognition and similarity search", *International Workshop on Content-Based Multimedia Indexing (CBMI)*, 2015.  
[7] O. Seddati, S. Dupont, S. Mahmoudi, "DeepSketch 2: Deep convolutional neural networks for partial sketch recognition", *International Workshop on Content-Based Multimedia Indexing (CBMI)*, 2016.  
[8] Y. Li, Y.Z. Song, S. Gong, "Sketch recognition by ensemble matching of structured features", *British Machine Vision Conference (BMVC)*, 2013.  
[9] L. Liu, F. Shen, Y. Shen, X. Liu, L. Shao, "Deep sketch hashing: Fast free-hand sketch-based image retrieval", *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, ss. 2862-2871, 2017.  
[10] R.G. Schneider, T. Tuytelaars, "Sketch classification and classification-driven analysis using fisher vectors", *ACM Transactions on Graphics (TOG)*, vol. 33(6), ss. 174:1-9, 2014.  
[11] P. Sangkloy, N. Burnell, C. Ham, J. Hays, "The sketchy database: Learning to retrieve badly drawn bunnies", *ACM Transactions on Graphics (TOG)*, vol. 35(4), ss. 119:1-12, 2016.  
[12] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg ve L. Fei-Fei, "ImageNet large scale visual recognition challenge", *International Journal of Computer Vision (IJCV)*, vol. 115, ss. 211-252, 2015.  
[13] J. Deng, W. Dong, R. Socher, L.J. Li, K. Li, L. Fei-Fei, "ImageNet: A large-scale hierarchical image database", *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, ss. 248-255, 2009.  
[14] A. Krizhevsky, I. Sutskever ve G. E. Hinton, "ImageNet classification with deep convolutional neural networks", *Advances in Neural Information Processing Systems (NIPS)*, ss. 1106-1114, 2012.  
[15] K. Simonyan, A. Zisserman, "Very deep convolutional networks for large-scale image recognition", *arXiv preprint arXiv:1409.1556*, 2014.  
[16] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke ve A. Rabinovich, "Going deeper with convolutions", *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, ss. 1-9, 2015.  
[17] F.I. Eyiokur, D. Yaman, H.K. Ekenel, "Domain adaptation for ear recognition using deep convolutional neural networks", *IET Biometrics*, 2017.  
[18] G. Ozbulak, Y. Aytaç, H.K. Ekenel, "How transferable are CNN-based features for age and gender classification?", *International Conference of the Biometrics Special Interest Group (BIOSIG)* IEEE, ss. 1-6, 2016.  
[19] J. Yosinski, J. Clune, Y. Bengio, H. Lipson, "How transferable are features in deep neural networks?", *Advances in Neural Information Processing Systems (NIPS)*, ss. 3320-3328, 2014.  
[20] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, Y. Bengio, "Generative adversarial nets", *Advances in Neural Information Processing Systems (NIPS)*, ss. 2672-2680, 2014.